哈尔滨工业大学

硕士学位论文中期报告

题　目：基于道路预瞻信息的主动悬架控制策略研究

院　　（系）	航天学院
学　　科	控制科学与工程
导　　师	周洪仁
研　究　生	张甜雨
学　　号	24S004091
中期报告日期	2026 年 6 月

研究生院制

目　录

1 **课题来源、研究背景与研究意义** 1
1.1 课题来源 1
1.2 研究背景与意义 1
2 **国内外研究现状与问题分析** 2
2.1 道路预瞻信息建模与控制接口 2
2.2 主动悬架控制策略 2
3 **半车主动悬架模型与性能指标** 3
3.1 非线性半车动力学模型 3
3.2 评价指标与优化目标 4
4 **已完成的方法实现** 4
4.1 统一 Python 仿真框架 4
4.2 PID、SPDF 与 MPC 控制器 5
4.3 Transformer 强化学习控制器 6
4.4 方法合理性与一致性说明 8
5 **阶段实验与结果分析** 8
5.1 实验设置 8
5.2 结果对比与讨论 8
5.3 阶段性审查与改进说明 9
6 **基线保持神经 MPC 参数调度方法阶段性结果** 12
7 **中期阶段完成情况** 13
8 **存在问题、解决措施与后续计划** 14
8.1 存在问题 14
8.2 解决措施 14
8.3 建议补充实验 14
8.4 后续进度安排 15
9 **研究条件与经费保障** 15
10 **主要参考文献** 17

1 课题来源、研究背景与研究意义

1.1 课题来源

本课题来源于实验室承担的赛力斯集团股份有限公司主动悬架控制算法研究项目。课题面向智能汽车底盘主动控制需求，研究基于道路预瞻信息的半车主动悬架控制策略，重点解决复杂路面激励下车身垂向振动、俯仰振动、悬架动行程和轮胎动载荷之间的多目标协调问题。

1.2 研究背景与意义

悬架系统连接车身与车轮，其性能直接影响车辆乘坐舒适性、操纵稳定性和行驶安全性。传统被动悬架的刚度和阻尼参数固定，难以同时兼顾不同车速、载荷和路面等级下的多工况性能。半主动悬架能够调节阻尼但不能主动注入能量，主动悬架则可通过执行器施加控制力，在四象限内对车身和车轮运动进行协调控制，因而具有更高的性能上限[1,2]。

近年来，激光雷达、视觉和车载感知系统的发展使道路预瞻信息可由上游感知模块提前获取。与仅依赖车身响应的事后反馈控制相比，预瞻控制能够在车轮到达不平路面之前提前计算执行器动作，从而改善主动悬架对突变路面和随机路面激励的响应。现有研究表明，路面估计、模型预测控制和鲁棒控制均可提升悬架性能[3–5]，但在强非线性、参数不确定、多目标权衡和实时计算方面仍存在不足。

深度强化学习为主动悬架控制提供了新的数据驱动路径。TD3、DDPG、SAC 和 PPO 等算法能够在连续动作空间中学习非线性控制策略[6–9]。同时，Transformer 结构具备对序列信息建模的能力[10]，适合用于编码未来若干时刻的道路预瞻序列。因此，本课题围绕“机理模型 + 专家控制 + 预瞻强化学习”的技术路线，构建包含 PID、SPDF、MPC 和 Transformer 强化学习控制器的统一仿真比较框架，为后续实车和硬件在环验证奠定基础。

从科学问题看，本课题并非单纯追求某一控制器在单一路况下的最优指标，而是研究道路预瞻信息、非线性半车动力学和数据驱动控制策略之间的耦合关系。其核心问题可概括为：在执行器力限幅、悬架行程约束和轮胎接地安全约束同时存在时，如何利用有限预瞻长度内的道路高程序列，使车身垂向与俯仰振动得到协同抑制，并保证控制策略具有可解释性、实时性和跨路况泛化能力。

2 国内外研究现状与问题分析

2.1 道路预瞻信息建模与控制接口

道路信息可由基于车辆响应的间接估计或基于外部传感器的非接触测量获得。间接估计通常利用簧载质量加速度、悬架动行程和轮胎响应反推路面轮廓，典型方法包括卡尔曼滤波、滑模观测器、频域估计和数据驱动分类[4,11,12]。该类方法无需额外感知硬件，但只能在车辆受到激励后估计路面，难以满足主动悬架提前控制需求。

非接触测量通常利用视觉、激光雷达或多传感融合提前获取车前道路轮廓。本文不再将具体道路感知算法作为主要研究内容，而是假设上游感知系统已经输出沿车轮轨迹的道路高程序列，并重点研究该预瞻序列如何进入主动悬架控制器。设车速为 v、轴距为 $l = a + b$，前轮路面输入为 $z_{df}(t)$，则后轮路面输入可近似表示为

$$z_{dr}(t) = z_{df}\left(t - \frac{l}{v}\right), \tag{2-1}$$

预瞻控制器在当前时刻可获得长度为 N_p 的路面序列

$$\mathcal{P}(t) = \left\{\left[z_{df}(t + kT_p), z_{dr}(t + kT_p)\right]\right\}_{k=1}^{N_p}, \tag{2-2}$$

其中 T_p 为预瞻采样周期。该序列既可直接用于 MPC 预测，也可作为 Transformer 编码器的输入。

从现有文献看，路面感知研究已从“路面类别识别”逐步扩展到“用于控制的连续可预瞻高程序列重建”。基于视觉的路面分类方法[13–15]在数据集构建与部署方面进展较快，但直接服务悬架控制时，仍需解决标注与控制需求不一致的问题；基于时序模型的路面识别与估计方法[16]在动态工况下具有潜力，但其输出时延与置信度传播机制仍需与控制器联合设计。因此，本课题将预瞻信息统一抽象为“带有可量化时延、噪声和缺失特性的连续高程序列”，并将研究重点放在控制策略对该序列的利用效率和鲁棒性上。

2.2 主动悬架控制策略

经典反馈控制包括天棚控制、地棚控制、PID 控制等，优点是结构简单、实现成本低，适合作为工程基线和专家策略来源[17–20]。但此类方法通常依赖固定反馈结构，难以显式处理执行器限幅、悬架动行程和轮胎动载荷等多目标约束。LQR、鲁棒控制和滑模控制能够提升闭环稳定性与抗扰性[5,21]，但其性能依赖模型精度、

权重选取和参数整定经验。模型预测控制能够在有限时域内显式优化性能指标并处理约束，适用于道路预瞻主动悬架控制，但计算量较大，且在线求解稳定性受模型误差和初值影响。

本课题已有工作中实现了基于周期延迟反馈的指定时间滑模控制器，记为SPDF。该方法通过周期延迟项构造滑模面，使闭环状态在指定时间尺度内收敛，并通过连续饱和近似缓解抖振。相较 PID，SPDF 对车身垂向和俯仰振动具有更强抑制能力；相较 MPC，SPDF 不需要在线求解优化问题，实时性更好。

强化学习方法的优势在于能够从交互数据中直接优化闭环性能，并可融合模型控制器产生的专家经验。TD3 通过双评论家网络、延迟策略更新和目标策略平滑降低 Q 值过估计[7]；SAC 通过最大熵目标提高探索能力[8]；PPO 通过截断策略梯度提升训练稳定性[9]。这些算法为后续主动悬架智能控制器对比提供了基础。

3 半车主动悬架模型与性能指标

3.1 非线性半车动力学模型

本文采用四自由度半车主动悬架模型，状态向量定义为

$$x = \left[z_b, \dot{z}_b, \theta, \dot{\theta}, z_{wf}, \dot{z}_{wf}, z_{wr}, \dot{z}_{wr}\right]^{\mathrm{T}}, \tag{3-3}$$

其中 z_b 为车身质心垂向位移，θ 为车身俯仰角，z_{wf} 和 z_{wr} 分别为前、后非簧载质量垂向位移。前后悬架动行程为

$$\Delta y_f = z_b + a\sin\theta - z_{wf}, \qquad \Delta y_r = z_b - b\sin\theta - z_{wr}, \tag{3-4}$$

其速度形式为

$$\Delta \dot{y}_f = \dot{z}_b + a\dot{\theta}\cos\theta - \dot{z}_{wf}, \qquad \Delta \dot{y}_r = \dot{z}_b - b\dot{\theta}\cos\theta - \dot{z}_{wr}. \tag{3-5}$$

考虑悬架弹簧非线性和不对称阻尼，前后悬架力写为

$$F_{sf} = k_{f1}\Delta y_f + k_{nf1}\Delta y_f^3 + \frac{(b_e + b_c) + (b_e - b_c)\,\mathrm{sgn}(\Delta \dot{y}_f)}{2}\Delta \dot{y}_f, \tag{3-6}$$

$$F_{sr} = k_{r1}\Delta y_r + k_{nr1}\Delta y_r^3 + \frac{(b_e + b_c) + (b_e - b_c)\,\mathrm{sgn}(\Delta \dot{y}_r)}{2}\Delta \dot{y}_r. \tag{3-7}$$

轮胎等效力为

$$F_{tf} = k_{f2}(z_{wf} - z_{df}) + b_{f2}(\dot{z}_{wf} - \dot{z}_{df}), \tag{3-8}$$

$$F_{tr} = k_{r2}(z_{wr} - z_{dr}) + b_{r2}(\dot{z}_{wr} - \dot{z}_{dr}). \tag{3-9}$$

令主动控制力为 $u=[u_{af},u_{ar}]^{\mathrm{T}}$，则半车动力学方程为

$$m_b\ddot{z}_b=-F_{sf}-F_{sr}+u_{af}+u_{ar}, \tag{3-10}$$

$$I_p\ddot{\theta}=-aF_{sf}+bF_{sr}+au_{af}-bu_{ar}, \tag{3-11}$$

$$m_{wf}\ddot{z}_{wf}=F_{sf}-F_{tf}-u_{af}, \tag{3-12}$$

$$m_{wr}\ddot{z}_{wr}=F_{sr}-F_{tr}-u_{ar}. \tag{3-13}$$

仿真中采用四阶 Runge-Kutta 方法离散化，底层积分步长为 $T_s=0.001\,\mathrm{s}$，控制周期为 $T_c=0.01\,\mathrm{s}$。

3.2 评价指标与优化目标

主动悬架控制需要同时考虑舒适性、安全性和能耗。本文选取车身垂向加速度均方根 $RMS_{\ddot{z}_b}$、俯仰角加速度均方根 $RMS_{\ddot{\theta}}$、悬架动行程峰值、轮胎动载荷均方根、控制力峰值和控制能耗作为评价指标。对任一信号 $q(t)$，其均方根定义为

$$RMS_q=\sqrt{\frac{1}{T_2-T_1}\int_{T_1}^{T_2}q^2(t)\,\mathrm{d}t}, \tag{3-14}$$

其中 T_1 为稳定段起始时间，本文取 $T_1=1\,\mathrm{s}$。

MPC 和强化学习采用统一的多目标代价函数。连续时间形式可写为

$$\begin{aligned}J=\int_0^T\big(&w_1\ddot{z}_b^2+w_2\ddot{\theta}^2+w_3(\Delta y_f^2+\Delta y_r^2)\\&+w_4(F_{tf}^2+F_{tr}^2)+w_5\left\|u/u_{\max}\right\|_2^2\big)\mathrm{d}t.\end{aligned} \tag{3-15}$$

为避免将真实物理能耗与训练代价混淆，本文将控制输入相关项记为控制能耗指标，而不直接等同于执行器电能消耗。强化学习奖励函数取 $r_t=-\ell_t$，其中 ℓ_t 为式 (3-15) 在离散时刻的瞬时代价。该设计使智能体在降低车身振动的同时避免悬架击穿、轮胎跳动和执行器饱和。

4 已完成的方法实现

4.1 统一 Python 仿真框架

本阶段已完成纯 Python 半车主动悬架控制比较框架，工程位于 `D:/workspace/suspension_control_all`。框架包括非线性半车模型、ISO 随机路面和凸包路面生成、PID/SPDF/MPC 控制器、Transformer 强化学习控制器、训练脚本、评估脚本和结果可视化脚本。表4-1列出了当前实验采用的主要

参数。

表 4-1: 半车主动悬架模型与仿真主要参数

参数	符号	数值	单位
簧载质量	m_b	1200	kg
俯仰转动惯量	I_p	600	kg·m^2
前/后非簧载质量	m_{wf}, m_{wr}	100/100	kg
前/后悬架线性刚度	k_{f1}, k_{r1}	15000/15000	N/m
前/后轮胎刚度	k_{f2}, k_{r2}	200000/200000	N/m
拉伸/压缩阻尼	b_e, b_c	1500/1200	N·s/m
质心至前/后轴距离	a, b	1.2/1.5	m
执行器力限幅	$u_{\max}$	5000	N
模型积分步长	T_s	0.001	s
控制周期	T_c	0.01	s

4.2 PID、SPDF 与 MPC 控制器

PID 控制器以车身垂向位移和俯仰角为反馈误差，生成广义控制力 u_b 和 u_θ：

$$u_b = -K_{p,z} e_z - K_{i,z} \int e_z \, \mathrm{d}t - K_{d,z} \dot{e}_z, \tag{4-16}$$

$$u_\theta = -K_{p,\theta} e_\theta - K_{i,\theta} \int e_\theta \, \mathrm{d}t - K_{d,\theta} \dot{e}_\theta, \tag{4-17}$$

其中 $e_z = z_b - z_{b,\mathrm{ref}}$，$e_\theta = \theta - \theta_{\mathrm{ref}}$。本阶段以平衡位置为参考，即 $z_{b,\mathrm{ref}} = 0$、$\theta_{\mathrm{ref}} = 0$。广义控制力到前、后作动器力的分配关系为

$$\begin{bmatrix} u_{af} \\ u_{ar} \end{bmatrix} = \begin{bmatrix} \frac{b}{a+b} & \frac{1}{a+b} \\ \frac{a}{a+b} & -\frac{1}{a+b} \end{bmatrix} \begin{bmatrix} u_b \\ u_\theta \end{bmatrix}. \tag{4-18}$$

当前基线实验中两个通道采用同一数量级参数，设置为 $K_p = 5.0 \times 10^4$、$K_i = 5.0 \times 10^3$、$K_d = 5.0 \times 10^5$。后续将进一步开展分通道整定，以避免垂向与俯仰通道因量纲差异产生权重偏置。

SPDF 控制器以垂向和俯仰两个子系统为对象构造滑模变量

$$s_1 = \dot{z}_b + a_1 z_b + K_1(t) z_b(t-h), \tag{4-19}$$

$$s_2 = \dot{\theta} + a_2 \theta + K_2(t) \theta(t-h), \tag{4-20}$$

其中 $h = T/4$ 为周期延迟，$K_i(t)$ 为周期时变增益。控制律由模型补偿项、连续滑模项和不确定性补偿项组成：

$$v_i = \frac{1}{g_i}\left[-\frac{2}{\pi}\rho_i(t)\arctan\left(\frac{\rho_i(t)s_i}{\varepsilon}\right) - a_i\dot{e}_i - \dot{K}_i(t)e_i(t-h) - K_i(t)\dot{e}_i(t-h) + u_{i0} + v_{i0}\right], \tag{4-21}$$

其中 $i = 1, 2$ 分别对应垂向和俯仰子系统，$e_1 = z_b$、$e_2 = \theta$，g_i 表示广义控制输入到对应加速度通道的等效增益，$\rho_i(t)$ 为正的鲁棒增益，u_{i0} 和 v_{i0} 分别表示模型补偿与前馈修正项。当前实现中 $a_1 = a_2 = 40$，$\tau_1 = \tau_2 = 0.75$，$\varepsilon = 10^{-3}$。该形式用 $\arctan(\cdot)$ 替代理想符号函数，可在保持滑模鲁棒性的同时减弱高频抖振。

MPC 控制器利用式 (2-2) 的道路预瞻信息，在预测时域 $N = 10$ 内求解

$$\min_{u_0,\ldots,u_{N-1}} \sum_{k=0}^{N-1} \ell(x_k, u_k, \mathcal{P}_k) \quad \text{s.t.} \quad x_{k+1} = f_d(x_k, u_k, z_{d,k}), \quad |u_{af,k}|, |u_{ar,k}| \le u_{\max}. \tag{4-22}$$

其中 $f_d(\cdot)$ 为由四阶 Runge-Kutta 离散化得到的非线性状态转移函数，$\ell(\cdot)$ 与式 (3-15) 中的瞬时代价一致，$\mathcal{P}_k$ 为预测步 k 对应的道路预瞻输入。在线优化采用 L-BFGS-B 有界优化，最大迭代次数为 15，重规划间隔为 5 个控制周期。控制执行时仅施加当前时刻的第一组控制量，随后基于新的状态和预瞻序列滚动重算。

4.3 Transformer 强化学习控制器

强化学习观测由 14 维车辆状态特征和 $N_p = 10$ 步道路预瞻序列组成：

$$o_t = \left[x_t, \Delta y_{f,t}, \Delta y_{r,t}, \Delta \dot{y}_{f,t}, \Delta \dot{y}_{r,t}, \ddot{z}_{b,t}, \ddot{\theta}_t, \mathrm{vec}(\mathcal{P}_t)\right]. \tag{4-23}$$

基础状态经多层感知机编码，道路预瞻序列经位置编码和 Transformer Encoder 编码，二者拼接后输入 actor 和 critic 网络。TD3 critic 更新目标为

$$y_t = r_t + \gamma(1-d_t)\min_{j=1,2} Q_{\bar{\phi}_j}\left(o_{t+1}, \pi_{\bar{\theta}}(o_{t+1}) + \epsilon\right), \tag{4-24}$$

其中 ϵ 为截断高斯噪声。actor 更新目标综合 Q 值最大化、动作正则和专家行为克隆：

$$\begin{aligned} L_\pi = & -\lambda_Q \mathbb{E}\left[Q_{\phi_1}(o, \pi_\theta(o))\right] \\ & + \lambda_u \mathbb{E}\left[\left\| \frac{\pi_\theta(o)}{u_{\max}} \right\|_2^2\right] \\ & + \lambda_{BC} \mathbb{E}_{(o,u_E)}\left[\left\| \frac{\pi_\theta(o) - u_E}{u_{\max}} \right\|_2^2\right]. \end{aligned} \tag{4-25}$$

为避免不同量纲代价项对训练造成偏置，离散时刻瞬时代价进一步写为

$$\ell_t = \bar{w}_1 \left(\frac{\ddot{z}_{b,t}}{\ddot{z}_{b,\mathrm{ref}}}\right)^2 + \bar{w}_2 \left(\frac{\ddot{\theta}_t}{\ddot{\theta}_{\mathrm{ref}}}\right)^2 + \bar{w}_3 \left(\frac{\Delta y_{f,t}^2 + \Delta y_{r,t}^2}{\Delta y_{\mathrm{ref}}^2}\right) + \bar{w}_4 \left(\frac{F_{tf,t}^2 + F_{tr,t}^2}{F_{t,\mathrm{ref}}^2}\right) + \bar{w}_5 \left\| \frac{u_t}{u_{\max}} \right\|_2^2. \tag{4-26}$$

其中各参考量由被动悬架或基线控制器统计得到。该设计与式 (3-15) 保持一致，同时增强跨工况训练稳定性。TD3 主要用于连续控制基线，DDPG 用于检验单评论家确定性策略的性能上限，SAC 用于考察最大熵探索对复杂路况的适应性，PPO 用于提供训练稳定性较强的 on-policy 对照。当前工程已实现 TD3、DDPG、SAC 和 PPO 四类 Transformer 控制器，并支持以 PID、SPDF、MPC 生成的专家数据进行预训练和在线混合训练。

表 4-2: 强化学习训练与网络参数

参数	数值	说明
隐藏层规模	[256, 256]	actor/critic MLP
actor 学习率	5.0×10^{-5}	TD3 默认配置
critic 学习率	1.0×10^{-3}	TD3 默认配置
折扣因子	0.99	长期回报权重
软更新系数	0.005	target network 更新
batch size	128	经验回放采样
buffer size	200000	经验池容量
Transformer 层数	2	道路预瞻编码器
注意力头数	4	多头自注意力
预瞻嵌入维度	64	preview embedding

4.4 方法合理性与一致性说明

本报告中模型、控制器与实验评价保持以下一致性：

1. 统一状态与符号：动力学状态采用 $x = [z_b, \dot{z}_b, \theta, \dot{\theta}, z_{wf}, \dot{z}_{wf}, z_{wr}, \dot{z}_{wr}]^{\mathrm{T}}$，全文不混用其他记号。

2. 统一优化目标：MPC 与强化学习共享同源代价函数（连续形式见式 (3-15)，离散归一化形式见式 (4-26)），保证方法比较公平。

3. 统一约束边界：执行器限幅均采用 $|u_{af}|, |u_{ar}| \le u_{\max}$，并同步报告控制能耗指标与舒适性指标。

4. 统一评价窗口：所有 RMS 指标均在剔除前 1 s 瞬态后统计，避免不同控制器初值响应引入偏差。

5 阶段实验与结果分析

5.1 实验设置

本阶段完成了 PID、SPDF 和 MPC 三类控制器在三种路况下的基线对比实验。路况包括 ISO 8608 B 级随机路面、ISO 8608 C 级随机路面和凸包路面。B 级路面车速为 22.22 m/s，C 级路面车速为 8.33 m/s，凸包路面车速为 22.22 m/s。单回合仿真时长为 10 s，前 1 s 作为稳定段不参与 RMS 统计。MPC 使用道路预瞻，PID 与 SPDF 不使用道路预瞻。该设置用于比较反馈专家策略与预瞻优化策略的阶段性效果，不直接等同于最终算法优劣排序；后续将补充同等预瞻条件和同等约束权重下的公平对比。

5.2 结果对比与讨论

从表5-1可以看出，SPDF 在舒适性指标上表现最优。相较 PID，SPDF 在 Class B、Class C 和 Bump 路况下分别使车身垂向加速度 RMS 降低 70.9%、65.7% 和 84.2%，使俯仰角加速度 RMS 降低 51.1%、48.5% 和 75.7%。这说明周期延迟滑模结构能够有效抑制车身低频振动，并且在随机路面和冲击路面下均保持稳定。

MPC 在当前权重设置下呈现出另一类性能特征：其悬架动行程、轮胎动载荷和控制能耗指标较低，且累计回报优于 PID 和 SPDF，但车身加速度和俯仰加速度偏大。该现象表明当前 MPC 代价函数对执行器输入、悬架行程和轮胎动载荷的权重相对更敏感，而舒适性权重仍需进一步整定。因此，不能仅依据累计回报判定 MPC 已优于 SPDF；更合理的结论是，MPC 当前更接近低控制输入和低约束代价

表 5-1: 不同控制器在三类路况下的关键实验指标

路况	控制器	预瞻	$RMS_{\ddot{z}_b}$ m/s^2	$RMS_{\ddot{\theta}}$ rad/s^2	$\max\lvert\Delta y_f\rvert$ m	$\max\lvert\Delta y_r\rvert$ m	控制能耗指标 –	累计回报
Class B	PID	否	0.002536	0.004077	0.001864	0.001820	2.276	-1.017
	SPDF	否	0.000739	0.001996	0.001971	0.001949	2.463	-0.934
	MPC	是	0.018334	0.033621	0.001344	0.001615	1.26×10^{-5}	-0.821
Class C	PID	否	0.002712	0.005145	0.002948	0.002864	3.174	-1.831
	SPDF	否	0.000930	0.002648	0.003184	0.003157	3.418	-1.822
	MPC	是	0.016869	0.043745	0.001452	0.001444	2.32×10^{-5}	-1.104
Bump	PID	否	0.000820	0.000975	0.001371	0.001083	119.657	-391.828
	SPDF	否	0.000129	0.000237	0.001193	0.001166	138.876	-346.548
	MPC	是	0.008356	0.022546	0.006179	0.007990	25.895	-69.020

策略，而 SPDF 当前更接近舒适性优先策略。后续将通过归一化代价、权重网格搜索和约束软化策略提升 MPC 的舒适性表现，并将其作为专家数据源之一用于强化学习预训练。

5.3 阶段性审查与改进说明

面向中期评审，当前材料需要重点避免以下表述风险：

1. 强化学习 actor 损失函数必须包含完整的 Q 值项、动作正则项和专家行为克隆项，否则无法说明专家引导机制如何进入策略优化。本文已在式 (4-25) 中给出完整表达。

2. “累计回报更高”不能直接推出“综合性能最优”。在当前结果中，MPC 的累计回报优势主要来自代价权重偏向控制输入和约束项，舒适性指标仍需单独分析。

3. 多控制器比较必须明确是否使用预瞻信息、是否采用同一代价函数和同一评价窗口。本文已补充统一口径，避免比较结论被误读。

4. 文献调研不能停留在控制算法罗列，还需要说明道路预瞻信息以何种接口进入控制器。本文已将上游感知结果抽象为连续高程序列，避免将研究重点扩展到具体视觉重建流程。

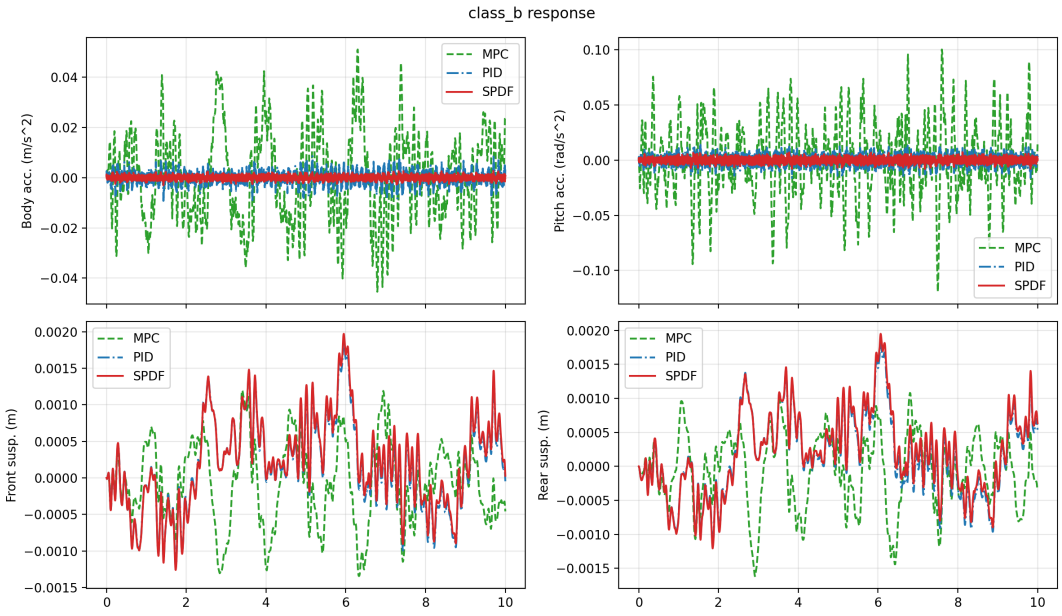


图 5-1: Class B 随机路面下三类控制器响应对比

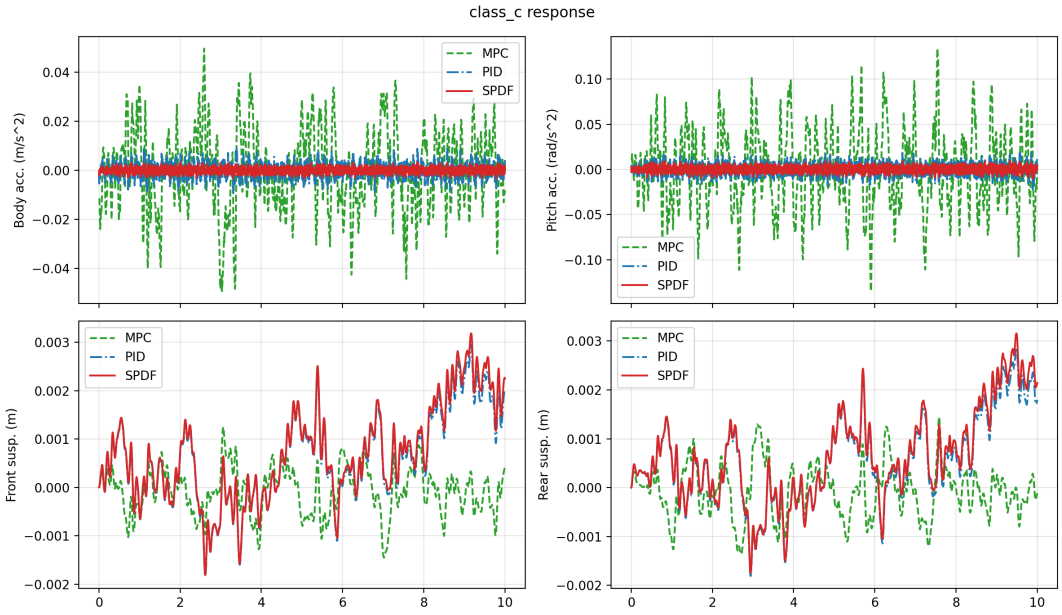


图 5-2: Class C 随机路面下三类控制器响应对比

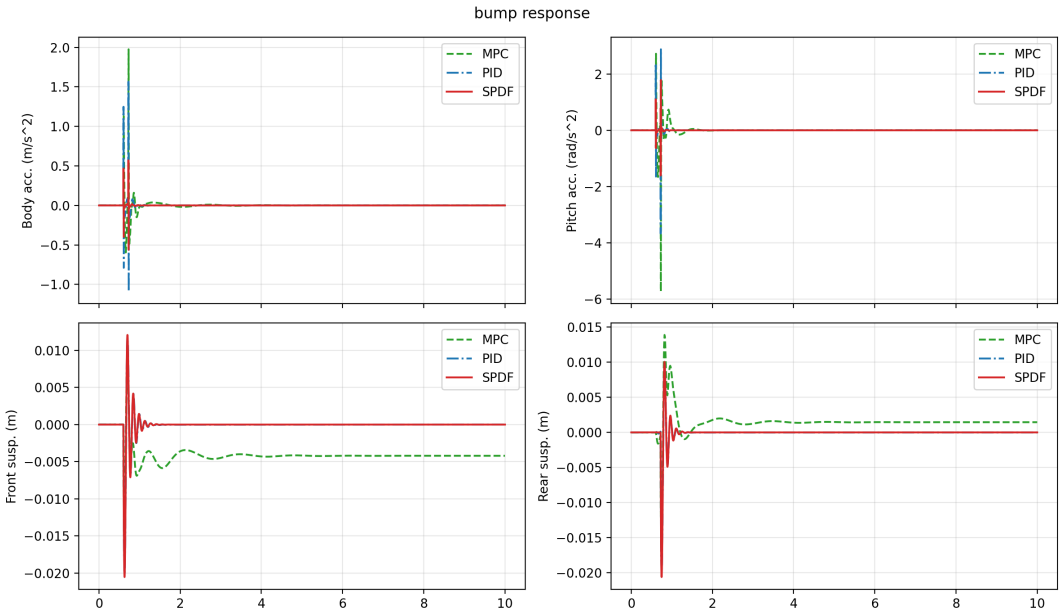


图 5-3: 凸包路面下三类控制器响应对比

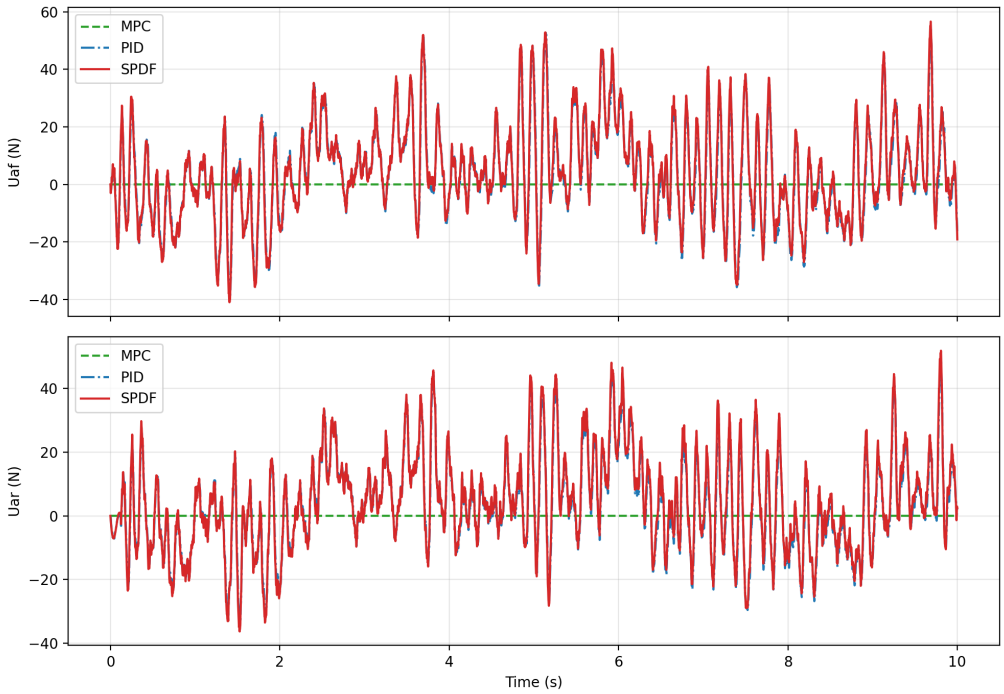


图 5-4: Class B 随机路面下前、后主动控制力对比

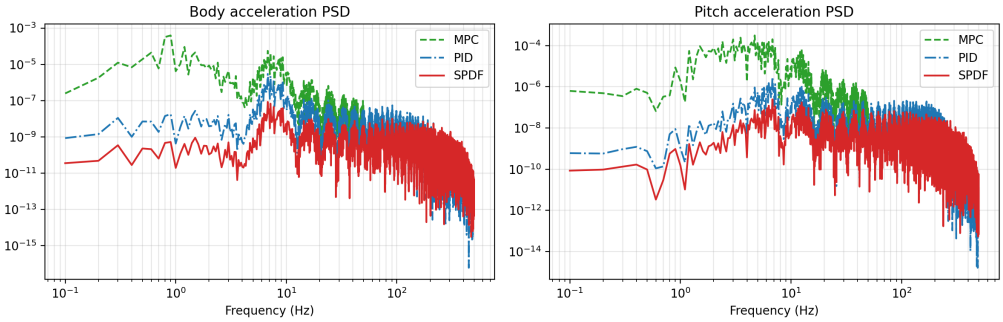


图 5-5: Class B 随机路面下车身垂向与俯仰加速度功率谱密度对比

6 基线保持神经 MPC 参数调度方法阶段性结果

在 MPC 舒适性权重仍需进一步整定的基础上，本阶段进一步探索了将强化学习用于 MPC 参数调度的思路。该路线不再将研究重点放在 PreScan 或视觉算法对道路轮廓的直接重建，而是假设上游感知模块已经输出可用于控制的道路预瞻序列或路况摘要特征，并研究如何利用这些信息自适应调整 MPC-like 控制器参数。为此，本文在当前工程中实现了基线保持神经 MPC 参数调度方法（Baseline-Preserving Neural MPC Parameter Scheduling, BP-NMPS）。

BP-NMPS 的核心思想是保留 reduced full-car MPC-lite 作为结构化、可解释的控制基线，而不是让强化学习策略直接输出四轮主动悬架力。策略网络的动作为 7 维 MPC 增益缩放系数，分别对应车身垂向、俯仰、侧倾及预瞻项等 MPC-lite 参数。这样可以将强化学习搜索空间从执行器力空间转化为控制器参数空间，降低高频力指令和约束违反风险。策略均值头采用零初始化，使 deterministic policy 初始严格等价于 fixed MPC-lite；训练过程中加入 anchor 正则、基线退化惩罚和正优势样本蒸馏，使策略只有在采样证据支持时才偏离基线。

为避免将训练探索过程中的偶然最优样本误认为可部署策略，实验报告同时区分 sampled best、raw deterministic policy 和 deployed policy。进一步地，BP-NMPS 引入校准集部署门控：训练结束后，deterministic policy 先在训练/校准场景上与 fixed MPC-lite 比较；若校准得分没有优于基线，则 checkpoint 记录部署门控激活，并在 held-out 评估和控制器部署时回退到 fixed MPC-lite。该机制保证学习到的参数调度只有在训练证据支持时才被实际部署。

表6-1给出了 5 个随机种子的 held-out 实验结果。训练/校准场景为 class_b_correlated、class_c_correlated 和 sine_roll，测试场景为 pothole_roll 和 mixed_full。结果显示，部署后的 BP-NMPS 在 5 个随机种子上均不劣于 fixed MPC-

表 6-1: BP-NMPS 多随机种子 held-out 实验结果

随机种子	固定 MPC 得分	BP-NMPS 得分	得分差值	unsafe 差值	门控	是否支持
42	2.65188	2.64739	-0.00450	0	关闭	是
43	2.65188	2.65188	0.00000	0	开启	是
44	2.65188	2.65188	0.00000	0	开启	是
45	2.65188	2.64981	-0.00207	0	关闭	是
46	2.65188	2.65188	0.00000	0	开启	是
平均			-0.00131	0		1.000

lite，支持率为 1.000，平均得分差值为 -0.00131，unsafe steps 差值为 0。其中种子 42 和 45 直接部署学习到的参数调度并取得得分改进；种子 43、44 和 46 由于校准集表现不足而触发门控，自动回退到 fixed MPC-lite。该结果说明，当前 BP-NMPS 更适合被表述为一种保守的自适应 MPC 参数调度器，而不是无约束替代 MPC 的黑箱强化学习控制器。

7 中期阶段完成情况

截至目前，本课题已完成以下工作：

1. 建立了包含参数不确定性、非线性弹簧和不对称阻尼的半车主动悬架数学模型，并完成 Python 数值仿真实现。

2. 实现了 ISO 随机路面与凸包路面生成模块，支持前后轮延迟输入和道路预瞻序列输出。

3. 实现并验证了 PID、SPDF 和 MPC 控制器，形成可复现实验脚本和统一评价指标。

4. 搭建了 Transformer-TD3、Transformer-DDPG、Transformer-SAC 和 Transformer-PPO 强化学习控制器框架。

5. 设计了专家经验引导机制，包括专家回放池、行为克隆预训练和训练过程中的 BC 正则项。

6. 完成了三类典型路况下 PID/SPDF/MPC 基线对比实验，生成了指标表、响应曲线、控制力曲线和 PSD 曲线。

7. 实现了基线保持神经 MPC 参数调度方法 BP-NMPS，并完成 5 个随机种子的 held-out 验证实验，初步证明其在部署门控约束下能够保持对 fixed MPC-lite 的

不劣性并取得平均得分改进。

8 存在问题、解决措施与后续计划

8.1 存在问题

当前研究仍存在四类问题。第一，MPC 的舒适性权重尚未充分整定，当前结果更偏向降低控制输入和约束代价，需要通过归一化权重和多目标搜索重新平衡舒适性、安全性与能耗指标。第二，强化学习控制器框架已实现，BP-NMPS 已取得初步多随机种子证据，但长周期训练、更多 held-out 路况和与直接力输出强化学习控制器的横向对比仍需补充，目前尚不足以支撑“智能控制器在所有工况下全面优于专家控制器”的强结论。第三，当前仿真主要采用解析路面模型生成理想预瞻序列，尚未系统评估上游感知模块可能带来的幅值噪声、时延偏差、空间采样误差和局部缺失对控制性能的影响。第四，三维可视化、硬件在环和实时性验证仍处于准备阶段，后续需要证明算法不仅在离线仿真中有效，也能满足实际控制周期约束。

8.2 解决措施

后续将从四个方面推进：一是对 MPC 代价进行量纲归一化和权重搜索，形成舒适性优先、综合性能优先和低能耗优先三类专家策略；二是继续完善 BP-NMPS，将其作为强化学习学习 MPC 参数的主线方法，并与直接力输出的 Transformer-TD3、Transformer-SAC 和 PPO 控制器进行对比；三是利用 PID、SPDF 和 MPC 轨迹构建专家数据集，对策略网络进行行为克隆预训练或参数调度蒸馏；四是在式 (2-2) 所示的预瞻序列中引入噪声、时延、截断和缺失等误差模型，验证控制器对非理想道路预瞻信息的鲁棒性。

8.3 建议补充实验

为提升后续论文说服力，建议补充以下实验：

1. 基线补充实验：增加被动悬架、LQR 或 Skyhook 等经典控制器，避免只有 PID/SPDF/MPC 三类结果导致基线层次不足。

2. 权重敏感性实验：对式 (3-15) 和式 (4-26) 中的权重进行网格搜索，给出舒适性-能耗-稳定性 Pareto 前沿。

3. 预瞻误差鲁棒性实验：在预瞻序列中注入幅值噪声、时延偏差和截断误差，评估 MPC 与强化学习控制器性能退化曲线。

4. 泛化实验：训练于 B/C 路况，测试于未见路况（如 A、D 级或组合路况），验证策略跨工况泛化能力。

5. 消融实验：分别去除 Transformer 编码器、行为克隆项、专家回放池，量化各模块贡献。

6. 统计可靠性实验：每组随机路面至少采用多个随机种子重复仿真，报告均值、标准差和显著性检验结果。

7. 计算开销与实时性实验：统计平均单步时延、95% 分位时延和约束违例率，评估硬件在环部署可行性。

8. 参数不确定性蒙特卡洛实验：对 m_b、I_p、阻尼和刚度参数扰动，比较各控制器稳健性。

8.4 后续进度安排

表 8-1: 后续研究计划

时间	主要任务
2026 年 5 月至 6 月	完成 MPC 权重整定、专家数据采集与数据质量筛选，形成不少于 2 万条有效专家样本。
2026 年 6 月至 8 月	完善 BP-NMPS 参数学习实验，并以 Transformer-TD3、Transformer-SAC 和 PPO 作为直接力输出对照组，比较参数调度与端到端控制的性能和安全性。
2026 年 8 月至 10 月	构建非理想道路预瞻信息模型，分析预瞻噪声、时延、截断长度和局部缺失对控制性能的影响。
2026 年 10 月至 12 月	完成硬件在环或实车条件准备，开展实时性和安全性验证。
2026 年 12 月至 2027 年 1 月	汇总实验结果，撰写学位论文和相关学术论文。

9 研究条件与经费保障

实验室已具备主动悬架系统实车平台、NI 硬件平台和高性能计算工作站，可支持算法训练、仿真验证、硬件在环实验和后续实车测试。当前 Python 框架可在

普通工作站上完成数值实验，强化学习训练可利用 GPU 加速。课题依托企业项目和实验室现有设备开展，研究条件能够满足后续工作需要。

10 主要参考文献

[1] Fekry A R, Oraby W A-H, Ali M A. Vehicle body pitch control through integration of MR damping system implemented in both vehicle suspension and front-end structure[J]. Proceedings of the Institution of Mechanical Engineers, Part D: Journal of Automobile Engineering, 2023, 237(5): 1082-1092.

[2] BalaMurugan L, Jancirani J. An investigation on semi-active suspension damper and control strategies for vehicle ride comfort and road holding[J]. Proceedings of the Institution of Mechanical Engineers, Part I: Journal of Systems and Control Engineering, 2012, 226(8): 1119-1129.

[3] Qin Y, Wei C, Tang X, et al. A novel nonlinear road profile classification approach for controllable suspension system: Simulation and experimental validation[J]. Mechanical Systems and Signal Processing, 2019, 125: 79-98.

[4] Tudón-Martínez J C, Fergani S, Sename O, et al. Adaptive Road Profile Estimation in Semiactive Car Suspensions[J]. IEEE Transactions on Control Systems Technology, 2015, 23(6): 2293-2305.

[5] Moradi S M, Akbari A, Mirzaei M. An offline LMI-based robust model predictive control of vehicle active suspension system with parameter uncertainty[J]. Transactions of the Institute of Measurement and Control, 2019, 41(6): 1699-1711.

[6] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous Control with Deep Reinforcement Learning[C] // International Conference on Learning Representations. 2016.

[7] Fujimoto S, van Hoof H, Meger D. Addressing Function Approximation Error in Actor-Critic Methods[C] // Proceedings of the 35th International Conference on Machine Learning. 2018: 1587-1596.

[8] Haarnoja T, Zhou A, Abbeel P, et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[C] // Proceedings of the 35th International Conference on Machine Learning. 2018: 1861-1870.

[9] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[10] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[11] Liu W, Wang R, Ding R, et al. On-line estimation of road profile in semi-active suspension based on unsprung mass acceleration[J]. Mechanical Systems and Signal

Processing, 2020, 135: 106370.

[12] Qin Y, Dong M, Zhao F, et al. Road profile classification for vehicle semi-active suspension system based on Adaptive Neuro-Fuzzy Inference System[C] // 2015 54th IEEE Conference on Decision and Control (CDC). 2015: 1533-1538.

[13] Cheng L, Zhang X, Shen J. Road surface condition classification using deep learning[J]. Journal of Visual Communication and Image Representation, 2019, 64: 102638.

[14] Yang G, Wang K C, Li J Q, et al. Automatic pavement type recognition for image-based pavement condition survey using convolutional neural network[J]. Journal of Computing in Civil Engineering, 2021, 35(1): 04020060.

[15] Zhao T, He J, Lv J, et al. A comprehensive implementation of road surface classification for vehicle driving assistance: Dataset, models, and deployment[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(8): 8361-8370.

[16] Liang G, Zhao T, Shangguan Z, et al. Experimental study of road identification by LSTM with application to adaptive suspension damping control[J]. Mechanical Systems and Signal Processing, 2022, 177: 109197.

[17] Karnopp D, Crosby M J, Harwood R A. Vibration control using semi-active force generators[J]. Journal of Engineering for Industry, 1974, 96(2): 619-626.

[18] Liu C, Chen L, Yang X, et al. General theory of skyhook control and its application to semi-active suspension control strategy design[J]. IEEE Access, 2019, 7: 101552-101560.

[19] Åström K, Hägglund T. PID Controllers: Theory, Design, and Tuning[M]. Research Triangle Park, NC, USA: ISA - The Instrumentation, Systems and Automation Society, 1995.

[20] Ekoru J E D, Dahunsi O A, Pedro J O. PID control of a nonlinear half-car active suspension system via force feedback[C] // IEEE Africon '11. 2011: 1-6.

[21] Zou J, Zuo X. Active suspension LQR control based on modified differential evolutionary algorithm optimization[J]. Journal of Vibroengineering, 2024, 26(5): 1150-1165.